LABORATORIO 4

Semilleros
by DSRP

Ejercicios

En este ejercicio, aprenderá a mejorar los resultados del entrenamiento al incluir **Early Stopping Callback** para evitar el **overfitting** (sobreajuste).

Cuando esté listo, ejecute la siguiente celda para configurar todo.

[1]:

```
# Setup plotting
import matplotlib.pyplot as plt
plt.style.use('seaborn-whitegrid')
# Set Matplotlib defaults
plt.rc('figure', autolayout=True)
plt.rc('axes', labelweight='bold', labelsize='large',
       titleweight='bold', titlesize=18, titlepad=10)
plt.rc('animation', html='html5')

# Setup feedback system
from learntools.core import binder
binder.bind(globals())
from learntools.deep_learning_intro.ex4 import *
```

Semilleros by DSRP

Ejercicios

Primero cargue el conjunto de datos de Spotify. Su tarea será predecir la popularidad de una canción en función de varias características de audio, como "**tempo**", "**danceability**" y "**mode**".

```
import pandas as pd
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import make_column_transformer
from sklearn.model_selection import GroupShuffleSplit
```

```
from tensorflow import keras
from tensorflow.keras import layers
from tensorflow.keras import callbacks

spotify = pd.read_csv('../input/dl-course-data/spotify.csv')

X = spotify.copy().dropna()
y = X.pop('track_popularity')
artists = X['track_artist']

features_num = ['danceability', 'energy', 'key', 'loudness', 'mode',
                'speechiness', 'acousticness', 'instrumentalness',
                'liveness', 'valence', 'tempo', 'duration_ms']
features_cat = ['playlist_genre']

preprocessor = make_column_transformer(
    (StandardScaler(), features_num),
    (OneHotEncoder(), features_cat),
)

# We'll do a "grouped" split to keep all of an artist's songs in one
# split or the other. This is to help prevent signal leakage.
def group_split(X, y, group, train_size=0.75):
    splitter = GroupShuffleSplit(train_size=train_size)
    train, test = next(splitter.split(X, y, groups=group))
    return (X.iloc[train], X.iloc[test], y.iloc[train], y.iloc[test])

X_train, X_valid, y_train, y_valid = group_split(X, y, artists)

X_train = preprocessor.fit_transform(X_train)
X_valid = preprocessor.transform(X_valid)
y_train = y_train / 100 # popularity is on a scale 0-100, so this rescales to 0-1.
y_valid = y_valid / 100

input_shape = [X_train.shape[1]]
print("Input shape: {}".format(input_shape))
```

```
Input shape: [18]
```

Semilleros by DSRP

Ejercicios

Comencemos con la red más simple, un modelo lineal. Este modelo tiene poca capacidad.
Ejecute esta siguiente celda sin ningún cambio para entrenar un modelo lineal en el conjunto de datos de Spotify.

```
model = keras.Sequential([
    layers.Dense(1, input_shape=input_shape),
])
model.compile(
    optimizer='adam',
    loss='mae',
)
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=512,
    epochs=50,
    verbose=0, # suppress output since we'll plot the curves
)
history_df = pd.DataFrame(history.history)
history_df.loc[0:, ['loss', 'val_loss']].plot()
print("Minimum Validation Loss: {:0.4f}".format(history_df['val_loss'].min()));
```

```
Minimum Validation Loss: 0.1946
```

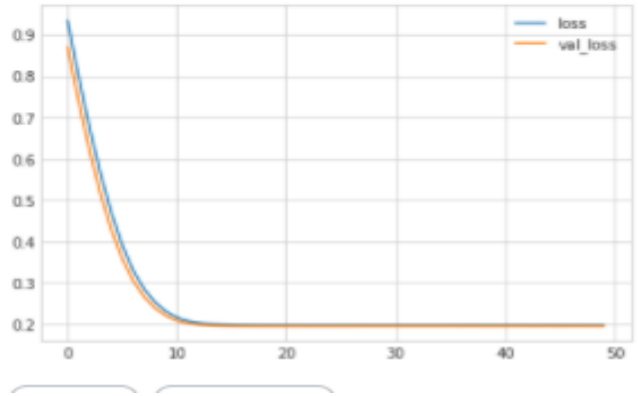


```
# Start the plot at epoch 10
history_df.loc[10:, ['loss', 'val_loss']].plot()
print("Minimum Validation Loss: {:0.4f}".format(history_df['val_loss'].min()));
```

```
Minimum Validation Loss: 0.1946
```

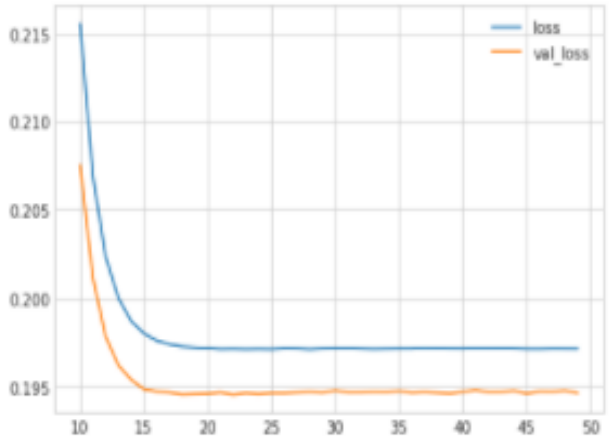

No es raro que las curvas sigan un patrón de "palo de hockey" como se ve aquí. Esto hace que la parte final del entrenamiento sea difícil de ver, así que comencemos en la época 10:

Semilleros by DSRP

Ejercicios

Paso1: Evaluate Baseline

¿Qué piensas? ¿Diría que este modelo está **underfitting** (desajustado), **overfitting** (sobreajustado), perfecto?

```
# View the solution (Run this cell to receive credit!)
q_1.check()
```

Correct:

La brecha entre estas curvas es bastante pequeña y la pérdida de validación nunca aumenta, por lo que es más probable que la red esté **underfitting** que **overfitting**. Valdría la pena experimentar con más capacidad para ver si ese es el caso.

Semilleros by DSRP

Ejercicios

Paso1: Evaluate Baseline

Ahora agreguemos algo de capacidad a nuestra red. Agregaremos tres capas ocultas con 128 unidades cada una. Ejecute la siguiente celda para entrenar la red y ver las curvas de aprendizaje.

```
]:
model = keras.Sequential([
    layers.Dense(128, activation='relu', input_shape=input_shape),
    layers.Dense(64, activation='relu'),
    layers.Dense(1)
])
model.compile(
    optimizer='adam',
    loss='mae',
)
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=512,
    epochs=50,
)
history_df = pd.DataFrame(history.history)
history_df.loc[:, ['loss', 'val_loss']].plot()
print("Minimum Validation Loss: {:0.4f}".format(history_df['val_loss'].min()));
```

```
Epoch 46/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1665 - val_loss: 0.2025
Epoch 47/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1655 - val_loss: 0.2033
Epoch 48/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1649 - val_loss: 0.2029
Epoch 49/50
48/48 [==============================] - 0s 3ms/step - loss: 0.1657 - val_loss: 0.2045
Epoch 50/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1649 - val_loss: 0.2042
Minimum Validation Loss: 0.1960
```

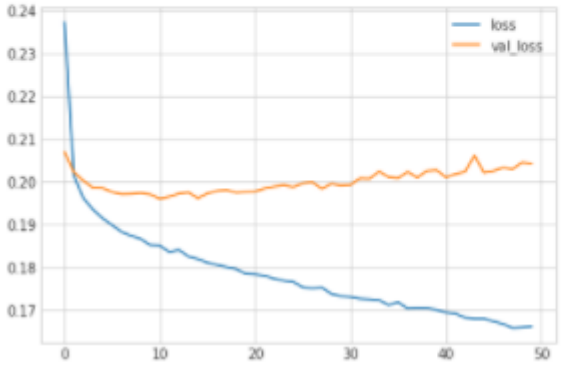

Semilleros by DSRP

Ejercicios

Paso2: Add Capacity

¿Cuál es su evaluación de estas curvas? ¿**underfitting** (Mal ajuste), **overfitting** (ajuste excesivo), correcto?

```
# View the solution (Run this cell to receive credit!)
q_2.check()
```

Correct:

Ahora, la pérdida de validación comienza a aumentar muy pronto, mientras que la pérdida de entrenamiento continúa disminuyendo. Esto indica que la red ha comenzado a adaptarse. En este punto, tendríamos que intentar algo para prevenirlo, ya sea reduciendo el número de unidades o mediante un método como la detención anticipada. (¡Veremos otro en la próxima lección!)

Semilleros by DSRP

Ejercicios

Paso3: Define Early Stopping Callback

Ahora defina **Early Stopping Callback** que espera 5 épocas (‘patients’) para un cambio en la pérdida de validación de al menos **0,001 (min_delta)** y mantiene los pesos con la mejor pérdida **(restore_best_weights).**

```
from tensorflow.keras import callbacks

# YOUR CODE HERE: define an early stopping callback
early_stopping = callbacks.EarlyStopping (
          min_delta=0.001,
          patience=5,
          restore_best_weights=True,
)

# Check your answer
q_3.check()
```

Correct

Semilleros by DSRP

Ejercicios

Paso3: Define Early Stopping Callback

Ahora ejecute esta celda para entrenar el modelo y obtener las curvas de aprendizaje. Observe el argumento de **callbacks** (devoluciones de llamada) en **model.fit**.

```
model = keras.Sequential([
    layers.Dense(128, activation='relu', input_shape=input_shape),
    layers.Dense(64, activation='relu'),
    layers.Dense(1)
])
model.compile(
    optimizer='adam',
    loss='mae',
)
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=512,
    epochs=50,
    callbacks=[early_stopping]
)
history_df = pd.DataFrame(history.history)
history_df.loc[:, ['loss', 'val_loss']].plot()
print("Minimum Validation Loss: {:0.4f}".format(history_df['val_loss'].min()));
```

```
Epoch 7/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1902 - val_loss: 0.1995
Epoch 8/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1867 - val_loss: 0.1968
Epoch 9/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1876 - val_loss: 0.1973
Epoch 10/50
48/48 [==============================] - 0s 4ms/step - loss: 0.1839 - val_loss: 0.1977
Minimum Validation Loss: 0.1968
```

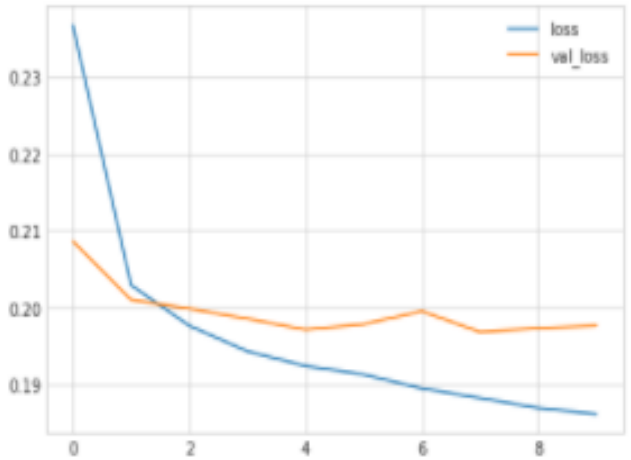

Semilleros by DSRP

Ejercicios

Paso4: Train and Interpret

¿Fue esto una mejora en comparación con el entrenamiento sin detenerse temprano?

Was this an improvement compared to training without early stopping?

+ Code + Markdown

```
# View the solution (Run this cell to receive credit!)
q_4.check()
```

Correct:

Callback (devolución de llamada) de **Early Stopping** (detención temprana) detuvo el entrenamiento una vez que la red comenzó a sobreajustarse. Además, al incluir **restore_best_weights** todavía podemos mantener el modelo donde la pérdida de validación fue más baja.

Semilleros by DSRP

LABORATORIO 5

Semilleros
by DSRP

Ejercicios

En este ejercicio, agregará la omisión al modelo de Spotify del Ejercicio 4 y verá cómo la normalización por lotes puede permitirle entrenar modelos con éxito en conjuntos de datos difíciles. ¡Ejecute la siguiente celda para comenzar!

```
# Setup plotting
import matplotlib.pyplot as plt
plt.style.use('seaborn-whitegrid')
# Set Matplotlib defaults
plt.rc('figure', autolayout=True)
plt.rc('axes', labelweight='bold', labelsize='large',
       titleweight='bold', titlesize=18, titlepad=10)
plt.rc('animation', html='html5')

# Setup feedback system
from learntools.core import binder
binder.bind(globals())
from learntools.deep_learning_intro.ex5 import *
```

Primero cargue el conjunto de datos de Spotify.

```
import pandas as pd
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import make_column_transformer
from sklearn.model_selection import GroupShuffleSplit

from tensorflow import keras
from tensorflow.keras import layers
from tensorflow.keras import callbacks

spotify = pd.read_csv('../input/dl-course-data/spotify.csv')

X = spotify.copy().dropna()
y = X.pop('track_popularity')
artists = X['track_artist']

features_num = ['danceability', 'energy', 'key', 'loudness', 'mode',
                'speechiness', 'acousticness', 'instrumentalness',
                'liveness', 'valence', 'tempo', 'duration_ms']
features_cat = ['playlist_genre']

preprocessor = make_column_transformer(
    (StandardScaler(), features_num),
    (OneHotEncoder(), features_cat),
)
```

```
def group_split(X, y, group, train_size=0.75):
    splitter = GroupShuffleSplit(train_size=train_size)
    train, test = next(splitter.split(X, y, groups=group))
    return (X.iloc[train], X.iloc[test], y.iloc[train], y.iloc[test])

X_train, X_valid, y_train, y_valid = group_split(X, y, artists)

X_train = preprocessor.fit_transform(X_train)
X_valid = preprocessor.transform(X_valid)
y_train = y_train / 100
y_valid = y_valid / 100

input_shape = [X_train.shape[1]]
print("Input shape: {}".format(input_shape))
```

```
Input shape: [18]
```

Semilleros by DSRP

Ejercicios

Paso1: Add Dropout to Spotify Model

Aquí está el último modelo del ejercicio 4. Agregue dos **dropout layers** (capas de abandono u omisión), una después de la capa Densa con 128 unidades y otra después de la capa Densa con 64 unidades. Establezca la tasa de abandono en ambos en 0,3.

```
# YOUR CODE HERE: Add two 30% dropout layers, one after 128 and one after 64
model = keras.Sequential([
    layers.Dense(128, activation='relu', input_shape=input_shape),
    layers.Dropout(rate=0.3),
    layers.Dense(64, activation='relu'),
    layers.Dropout(rate=0.3),
    layers.Dense(1)
])

# Check your answer
q_1.check()
```

Correct

Semilleros by DSRP

Ejercicios

Paso1: Add Dropout to Spotify Model

Ahora ejecute la siguiente celda para entrenar el modelo y vea el efecto de agregar abandonos.

```
model.compile(
    optimizer='adam',
    loss='mae',
)
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=512,
    epochs=50,
    verbose=0,
)
history_df = pd.DataFrame(history.history)
history_df.loc[:, ['loss', 'val_loss']].plot()
print("Minimum Validation Loss: {:0.4f}".format(history_df['val_loss'].min()))
```

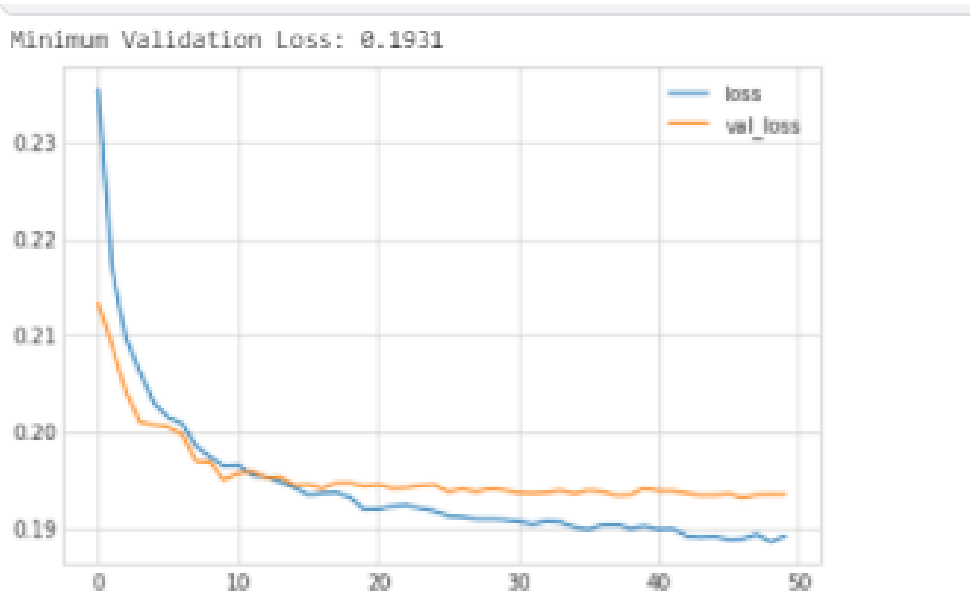

Semilleros by DSRP

Ejercicios

Paso2: Evaluate Dropout

Recuerde del ejercicio 4 que este modelo tendía a sobreajustar los datos alrededor de la época 5. ¿La adición de abandonos pareció ayudar a prevenir el sobreajuste esta vez?

```
# View the solution (Run this cell to receive credit!)
q_2.check()
```

Correct:

A partir de las curvas de aprendizaje, puede ver que la pérdida de validación permanece cerca de un mínimo constante aunque la pérdida de entrenamiento continúa disminuyendo. Entonces, podemos ver que agregar abandonos evitó el sobreajuste esta vez. Además, al dificultar que la red se ajuste a patrones espurios, la deserción puede haber alentado a la red a buscar más patrones verdaderos, posiblemente mejorando también la pérdida de validación).

Ahora, cambiaremos de tema para explorar cómo la normalización por lotes puede solucionar problemas en el entrenamiento.
Cargue el conjunto de datos Concrete. Esta vez no haremos ninguna estandarización. Esto hará que el efecto de la normalización de lotes sea mucho más evidente.

```
import pandas as pd

concrete = pd.read_csv('../input/dl-course-data/concrete.csv')
df = concrete.copy()

df_train = df.sample(frac=0.7, random_state=0)
df_valid = df.drop(df_train.index)

X_train = df_train.drop('CompressiveStrength', axis=1)
X_valid = df_valid.drop('CompressiveStrength', axis=1)
y_train = df_train['CompressiveStrength']
y_valid = df_valid['CompressiveStrength']

input_shape = [X_train.shape[1]]
```

Ejercicios

Paso2: Evaluate Dropout

Ejecute la siguiente celda para entrenar a la red con los datos de hormigón no estandarizados.

11]:

```
model = keras.Sequential([
    layers.Dense(512, activation='relu', input_shape=input_shape),
    layers.Dense(512, activation='relu'),
    layers.Dense(512, activation='relu'),
    layers.Dense(1),
])
model.compile(
    optimizer='sgd', # SGD is more sensitive to differences of scale
    loss='mae',
    metrics=['mae'],
)
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=64,
    epochs=100,
    verbose=0,
)

history_df = pd.DataFrame(history.history)
history_df.loc[0:, ['loss', 'val_loss']].plot()
print(("Minimum Validation Loss: {:0.4f}").format(history_df['val_loss'].min()))
```

```
Minimum Validation Loss: nan
```

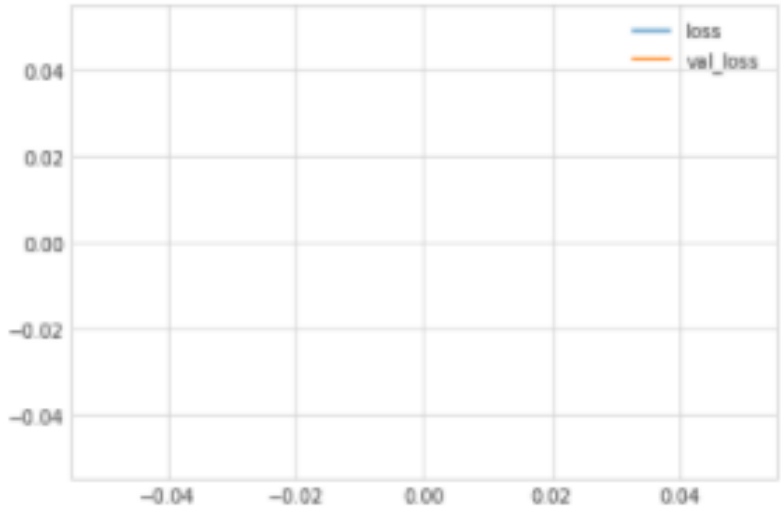

¿Terminaste con un gráfico en blanco? Intentar entrenar esta red en este conjunto de datos generalmente fallará. Incluso cuando converge (debido a una inicialización de peso afortunada), tiende a converger a un número muy grande.

Ejercicios

Paso3: Add batch Normalization Layers

La normalización por lotes puede ayudar a corregir problemas como este.

Agregue cuatro capas de BatchNormalization, una antes de cada una de las capas densas. (Recuerde mover el argumento input_shape a la nueva primera capa).

```
# YOUR CODE HERE: Add a BatchNormalization layer before each Dense layer
model = keras.Sequential([
        layers.BatchNormalization(input_shape=input_shape),
    layers.Dense(512, activation='relu'),
        layers.BatchNormalization(),
    layers.Dense(512, activation='relu'),
       layers.BatchNormalization(),
    layers.Dense(512, activation='relu'),
       layers.BatchNormalization(),
    layers.Dense(1),
])

# Check your answer
q_3.check()
```

Correct

Ejercicios

Paso3: Add batch Normalization Layers

Ejecute la siguiente celda para ver si la normalización por lotes nos permitirá entrenar el modelo.

```
model.compile(
    optimizer='sgd',
    loss='mae',
    metrics=['mae'],
)
EPOCHS = 100
history = model.fit(
    X_train, y_train,
    validation_data=(X_valid, y_valid),
    batch_size=64,
    epochs=EPOCHS,
    verbose=0,
)

history_df = pd.DataFrame(history.history)
history_df.loc[0:, ['loss', 'val_loss']].plot()
print(("Minimum Validation Loss: {:0.4f}").format(history_df['val_loss'].min()))
```

```
Minimum Validation Loss: 3.8706
```

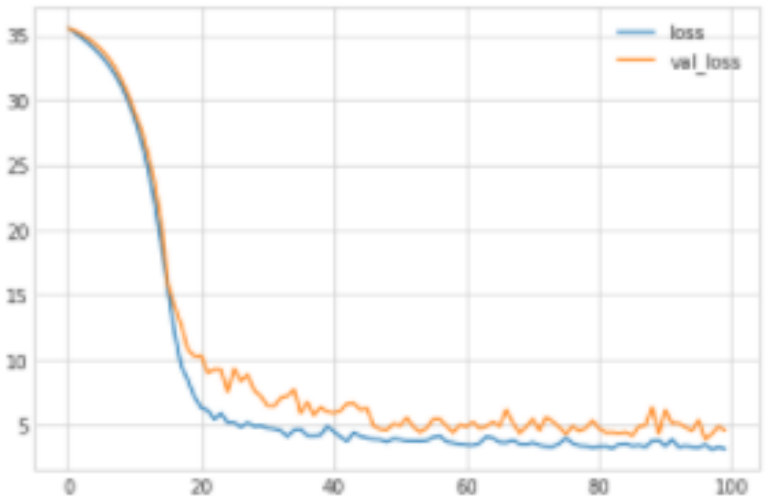

Ejercicios

Paso4: Evaluate batch Normalization

¿Le ayudó agregar la normalización por lotes?

```
# View the solution (Run this cell to receive credit!)
q_4.check()
```

Correct:

¡Puede ver que agregar la normalización por lotes fue una gran mejora en el primer intento! Al escalar de forma adaptativa los datos a medida que pasan a través de la red, la normalización por lotes puede permitirle entrenar modelos en conjuntos de datos difíciles.